INSTITUTO SUPERIOR MANUEL BELGRANO

Postes kilométricos

Dashboard de análisis de datos con GeoJSON real

Examen Parcial N° 2 | Programación Orientada al Análisis de Datos

Dato	Detalle
Carrera	Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial
Curso y sede	2do 4 | Godoy Cruz
Docente	Juan Caballero Gallar | Ciclo Lectivo 2026
Estudiante	Axel Fernández
Fecha de entrega	30/10/2026 - Aula Virtual
Fecha de preparación	17/10/2026

Rama de esta entrega: `codex/poad-parcial2-analisis` del repositorio público.

1. Proyecto

Resumen ejecutivo. El proyecto amplía el dashboard del primer parcial para explorar postes kilométricos publicados por IDE Transporte. Permite filtrar registros por distrito, ruta y progresiva, consultar su distribución y comparar una red neuronal con una línea base simple para estimar el campo `distancia`.

Problema y público. El GeoJSON contiene miles de registros que no son cómodos de inspeccionar fila por fila. El tablero organiza esa información en un mapa, KPIs y gráficos para estudiantes, analistas y equipos que necesitan explorar datos viales públicos. El resultado es exploratorio y no sustituye información oficial ni una decisión de ingeniería.

Stack tecnológico

Herramienta	Uso
Python y pandas	Lectura de properties, transformación de tipos, filtros y resúmenes.
NumPy y scikit-learn	Preparación numérica, MLPRegressor y métricas MAE/RMSE.
Dash y Plotly	Aplicación web local, mapa, gráficos interactivos y filtros.
Matplotlib y Seaborn	Gráficos estáticos complementarios.
ReportLab y Pillow	Generación del documento y anotación de capturas.
Git y Docker	Control local de versiones y alternativa de ejecución aislada.

Instalación y ejecución para programadores

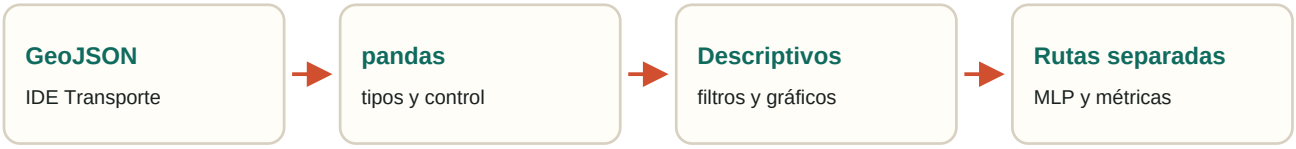
```
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
python app.py
# abrir http://127.0.0.1:8050
```

El GeoJSON ya está incluido. Para descargarlo de nuevo: `python src/download_data.py`. Para regenerar los gráficos: `python src/make_static_charts.py`. Para ver métricas en consola: `python src/analysis.py`.

2. Documentación técnica

Estructura. `app.py` inicia Dash y conecta filtros y gráficos; `src/analysis.py` contiene carga, limpieza, estadística y modelo; `src/download_data.py` descarga la fuente; `src/make_static_charts.py` genera visualizaciones estáticas; `src/generate_report.py` produce este PDF. El GeoJSON crudo está en `data/raw`, estilos y gráficos en `assets`, capturas en `screenshots` y el documento final en `output/pdf`.

Pipeline de datos



El programa lee `features[].properties` con pandas, convierte campos numéricos, conserva faltantes y normaliza espacios en campos de texto. Los descriptivos y gráficos usan los registros disponibles. Para el modelo, las filas sin `distancia` quedan fuera del entrenamiento, sin imputación.

Modelo analítico

La tarea es regresión supervisada: estimar `distancia` con `progresiva`, `latitud` y `longitud`. Un MLP de scikit-learn usa dos capas ocultas (32 y 16 neuronas), activación ReLU, estandarización y un máximo de 300 iteraciones con parada temprana. El entrenamiento limita BLAS a dos hilos de CPU. Los campos `id`, `id_mojon` y `desc` se excluyen: son identificadores o `desc` repite la progresiva. `cod_ruta` se usa solo para separar grupos, no como predictor.

Se reservó aproximadamente el 20% de las rutas completas (semilla 42): 21 rutas y 3.963 filas de prueba, sin compartir rutas con entrenamiento. La referencia base predice la mediana de distancia calculada en entrenamiento.

Método	MAE	RMSE
Base: mediana del entrenamiento	277,02	346,50
Red neuronal MLP	118,19	160,00

MAE es el error absoluto medio; RMSE penaliza más los errores grandes. Menor es mejor. Los valores se expresan en la escala publicada para la columna distancia; no se asigna una unidad no confirmada por el archivo. La comparación es una evaluación académica sobre este dataset, no una promesa de desempeño futuro.

Guía de estilo

Elemento	Definición
Tema	Operativo y sobrio; fondo papel, paneles claros y jerarquía tipográfica simple.
Paleta	Tinta #18201f; fondo #f6f2e9; panel #fffdf8; verde #106b5f; acento #d04f2f.
Tipografía	Avenir; alternativas Helvetica Neue y Helvetica.

3. Gobierno de datos

Fuente. GeoJSON público de IDE Transporte, capa `observ:_3.4.1.1.4.poste_1km_2018`. Abrir el servicio WFS de IDE Transporte. Se conserva la fuente cruda en `data/raw/postes_1km_2018.geojson`.

Transformación con pandas. Cada feature se convierte desde `properties` a una fila. Los campos numéricos se convierten con `pd.to_numeric(errors='coerce')`; los campos textuales se limpian con `strip()`. No se eliminan registros del DataFrame ni se imputan distancias. La red usa solo las filas con objetivo y predictores válidos.

Control sobre el archivo	Resultado
Features	27.143
Rutas y distritos	107 rutas; 24 distritos
Progresiva	media 799,1; mediana 502,0; Q1 176,0; Q3 1172,0; desvío 851,3; rango 0,0 a 4370,0 km
Distancia	24.728 completas; 2.415 faltantes (8,90%)
Año de ruta	2016 en los 27.143 registros; no hay variación temporal para pronosticar años.
Validación de coordenadas	0 registros fuera de latitud/longitud válidas.
IDs y duplicados	0 IDs de registro repetidos; 27.143 descripciones coinciden con progresiva.

Diccionario de datos

Campo	Descripción y uso
id	Identificador del registro en la fuente; no es predictor.
id_mojon	Identificador del mojón o poste; se excluye del modelo.
cod_ruta	Código de ruta; filtro del tablero y clave para separar train/test.
latitud	Coordenada geográfica; predictor numérico del MLP.
longitud	Coordenada geográfica; predictor numérico del MLP.
progresiva	Kilómetro o avance sobre la ruta; filtro, estadística y predictor.
ano_ruta	Año informado para la ruta; 2016 en este archivo.
distancia	Campo numérico objetivo para el modelo; contiene valores faltantes.
desc	Descripción corta; coincide con progresiva en los 27.143 registros.
distrito	Distrito o jurisdicción; filtro y dimensión descriptiva.

4. Guía de usuario

Glosario. Poste: registro georreferenciado de un punto kilométrico. **Ruta:** código vial. **Distrito:** jurisdicción asociada. **Progresiva:** kilometraje o avance informado. **MAE:** promedio del valor absoluto de los errores de predicción. **RMSE:** raíz del promedio del error al cuadrado, más sensible a errores grandes. **Línea base:** mediana de distancia del conjunto de entrenamiento.

Navegación. Elegí uno o más distritos y códigos de ruta en los menús; ajustá el control de progresiva. Las tarjetas de KPI, el mapa y los dos gráficos superiores responden a los filtros. Si limpiás un menú, el tablero muestra todos los valores de esa dimensión.

Modelo. El panel de análisis es global y no cambia con los filtros del mapa. Muestra el número de registros completos, las rutas reservadas, MAE de la red y mediana de progresiva. En el gráfico de comparación, cada punto corresponde a un caso de prueba; la diagonal punteada representa una estimación igual al valor real. El histograma resume la progresiva de todo el archivo.

Preguntas frecuentes

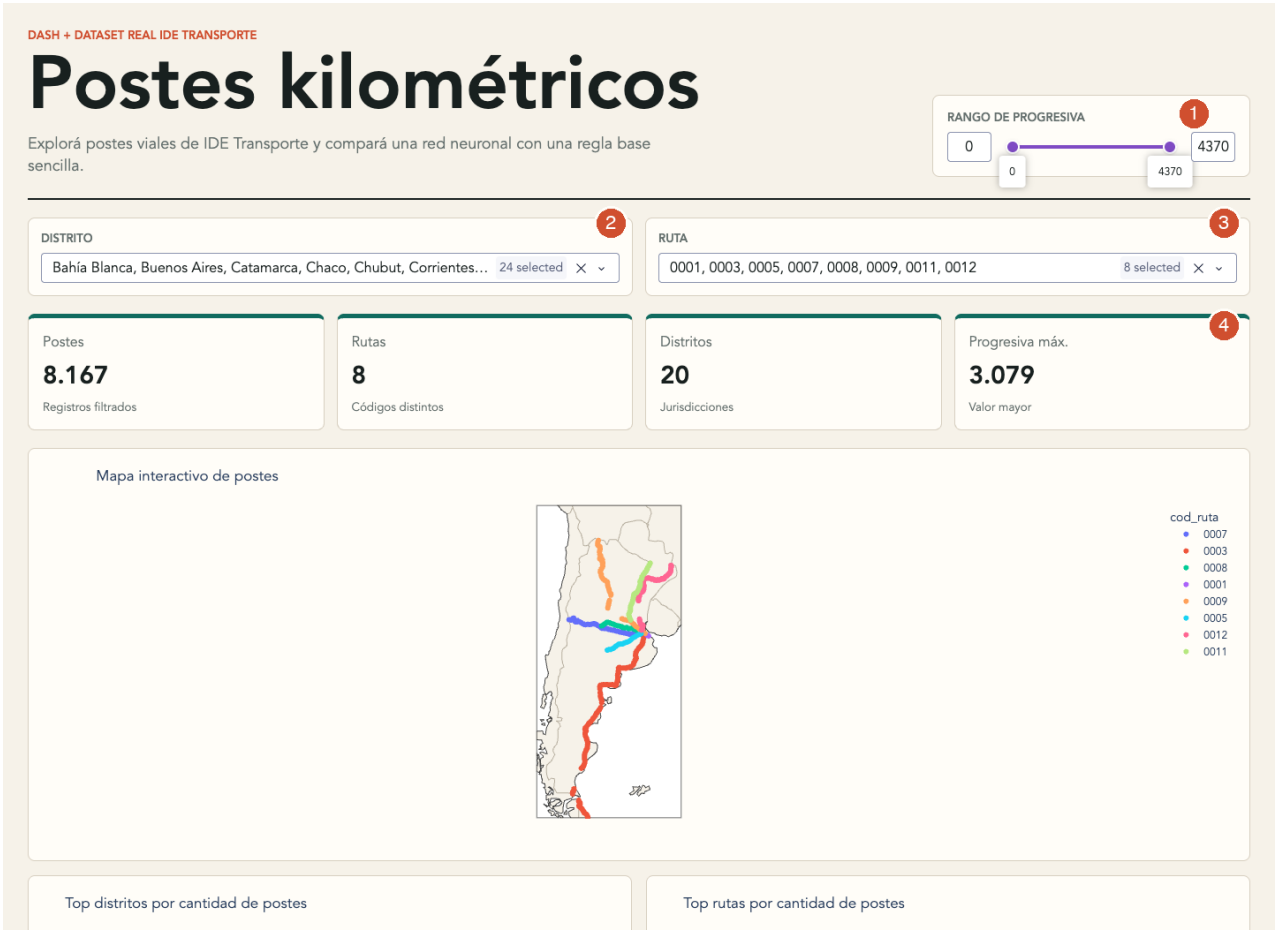
Pregunta	Respuesta
¿Por qué algunas distancias no entran al modelo?	La fuente tiene 2.415 objetivos faltantes. Se conservan en el tablero y se excluyen del entrenamiento y evaluación.
¿El MLP predice el futuro?	No. El archivo registra 2016 para todas las rutas. El modelo estima una columna existente y no es un pronóstico temporal.
¿Por qué la red usa rutas reservadas?	Para medir desempeño en rutas que no aportaron ejemplos al entrenamiento y reducir fuga de información entre filas de una misma ruta.
¿Qué significa un MAE menor?	Que el promedio de errores absolutos es más bajo en las unidades de la columna distancia.
¿Qué hago si falta el GeoJSON o el gráfico?	Ejecutá `python src/download_data.py` para bajar la fuente y `python src/make_static_charts.py` para recrear gráficos estáticos.
¿Cómo regenero la documentación?	Ejecutá `python -m src.generate_report` después de instalar requirements.txt.

Código de esta entrega: rama codex/poad-parcial2-analisis del repositorio público. El enlace abre esta versión del código.

Referencias: Documentación oficial de redes neuronales supervisadas de scikit-learn; documentación de pandas; material bibliográfico indicado en la consigna.

5. Captura del dashboard

La imagen muestra la vista principal. Los números marcan dónde están los controles y resultados interactivos.



N°	Elemento
1	Rango de progresiva y filtros de distrito/ruta.
2	Filtro de distrito.
3	Filtro de ruta.
4	KPIs recalculados según la selección.

6. Captura de gráficos interactivos

El mapa y los gráficos de barras pertenecen a la selección activa. El mapa puede mostrar una muestra reproducible de hasta 5.000 puntos para mantener fluidez.



N°	Elemento
1	Mapa geográfico de postes y leyenda por código de ruta.
2	Barras horizontales con el top 12 de distritos.
3	Barras verticales con el top 12 de rutas.

7. Captura del análisis

El panel inferior resume la evaluación por rutas completas. Las métricas provienen del conjunto de prueba y son independientes de los filtros del mapa.



N°	Elemento
1	Resumen estadístico y número de rutas reservadas.
2	MAE de la red y valor de referencia de la base mediana.
3	Comparación de predicción vs. valor real; cuanto más cerca de la diagonal, menor error.
4	Distribución de progresivas del GeoJSON.

Resultado de esta ejecución: MAE MLP 118,19 frente a 277,02 de la base; RMSE MLP 160,00 frente a 346,50. La métrica no garantiza el mismo resultado con otra descarga o en otros datos.